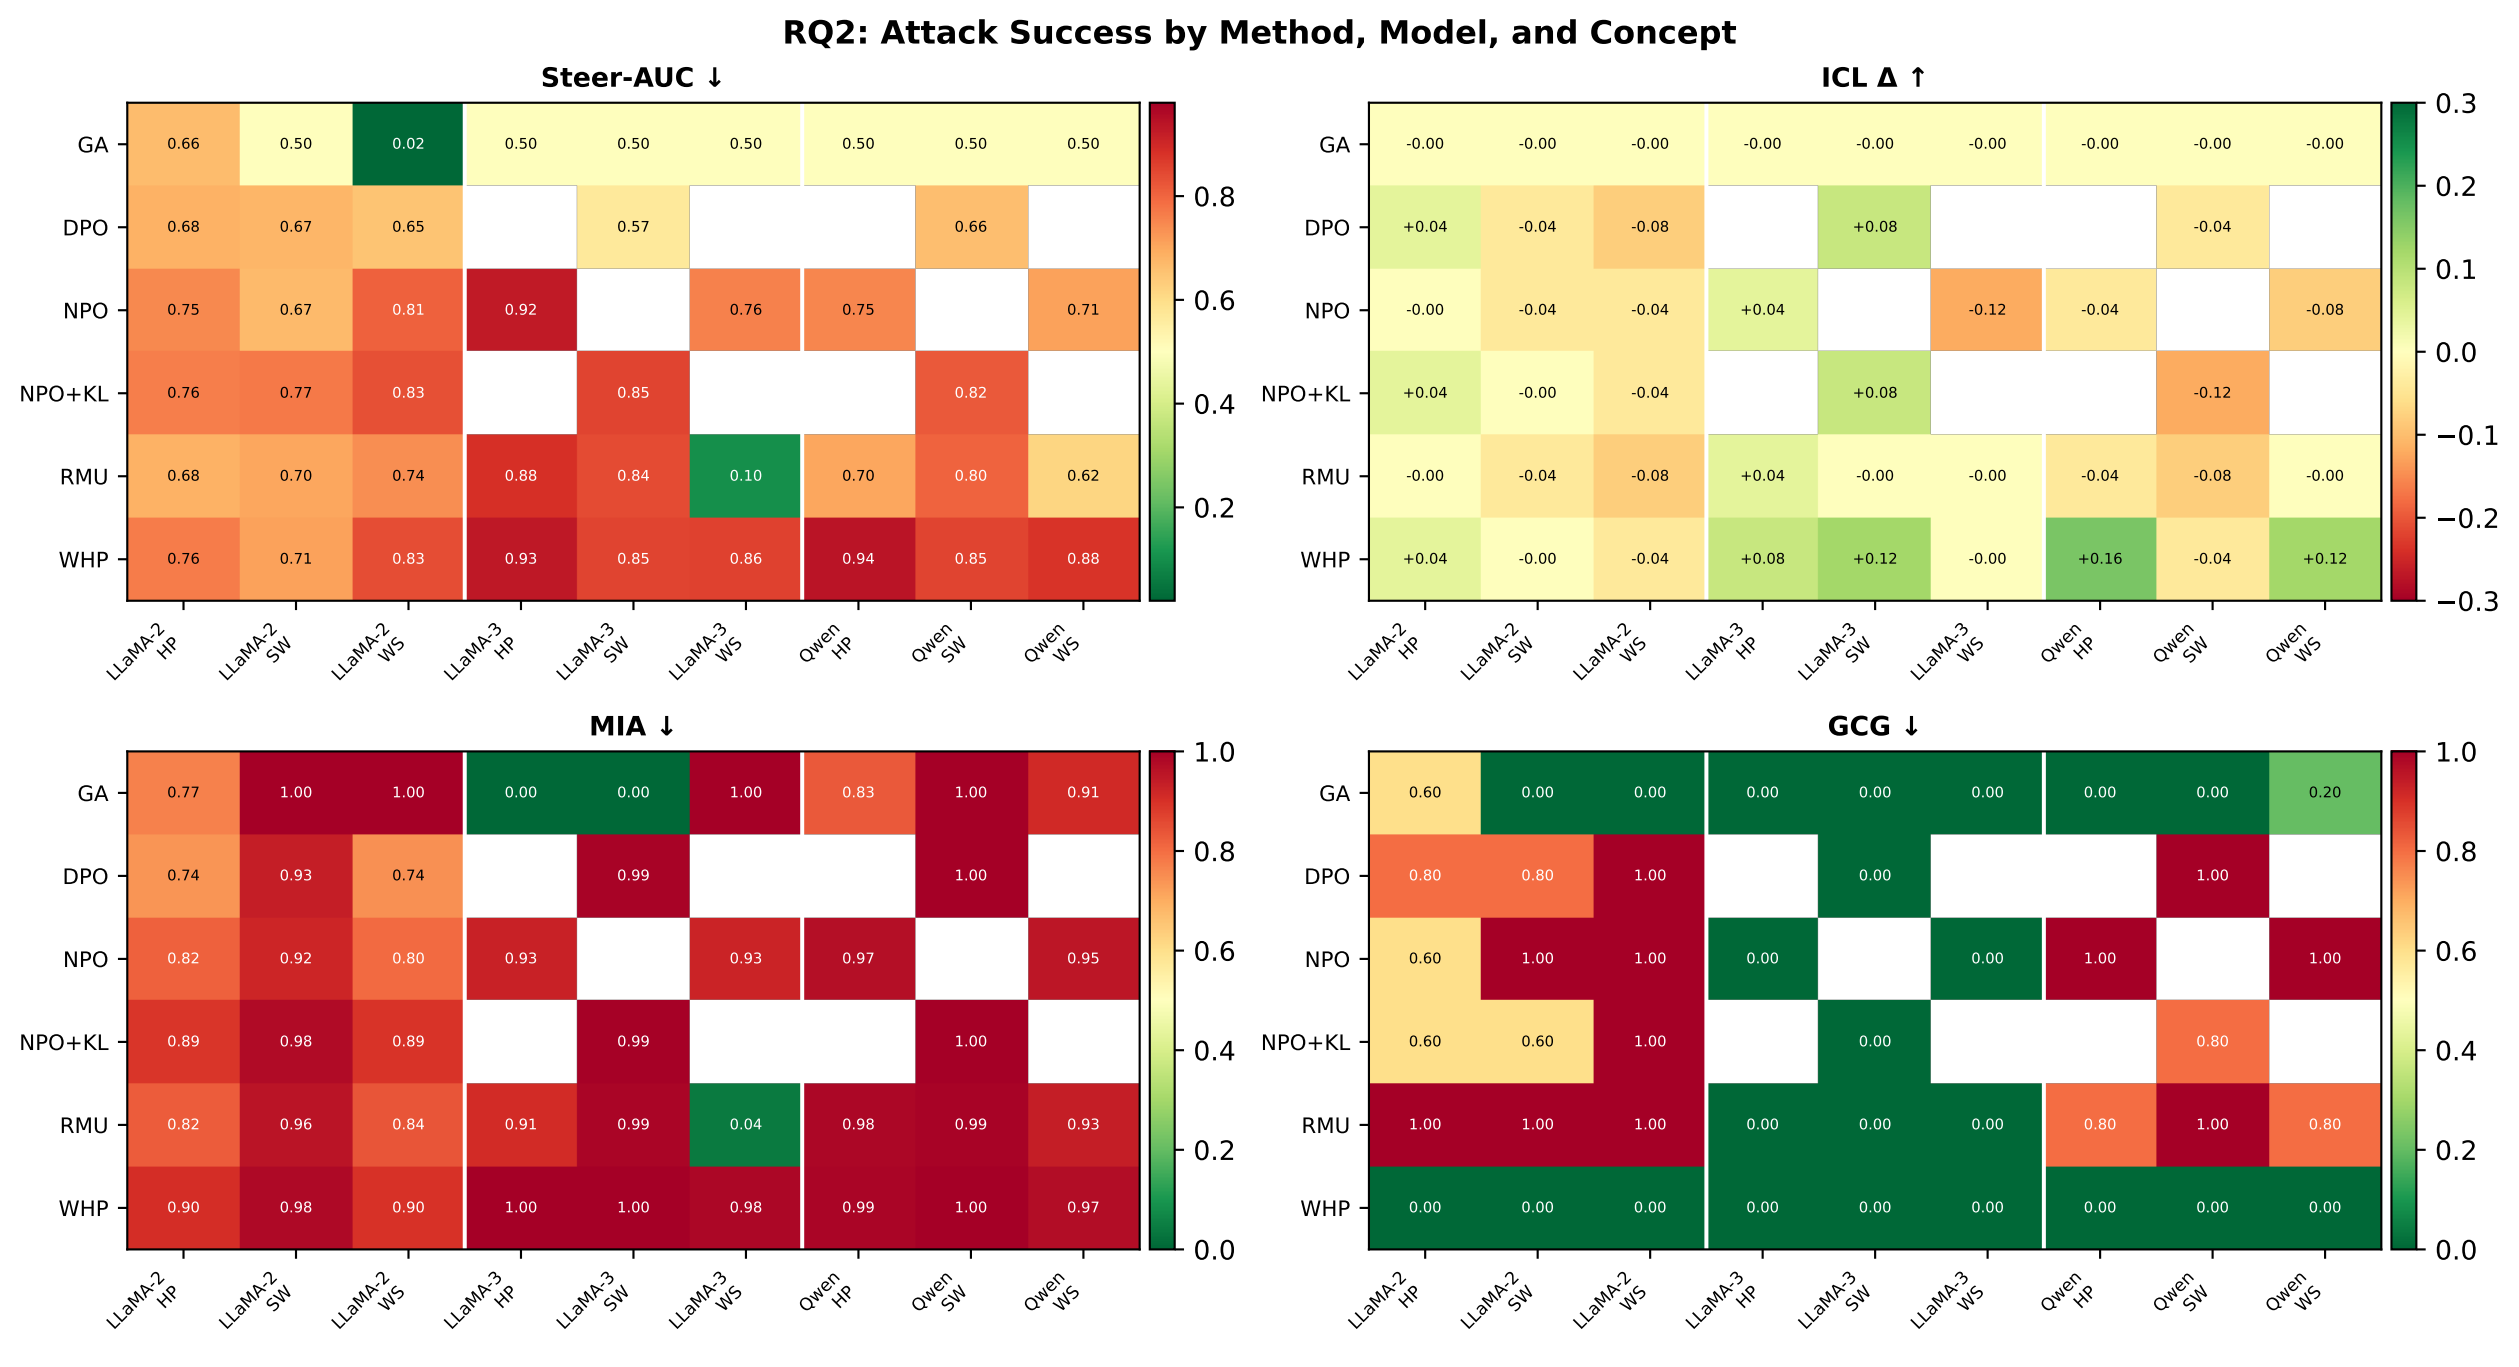
RQ2: Attack Success by Method, Model, and Concept
Steer-AUC ↓
ICL Δ ↑
MIA ↓
GCG ↓
GA
DPO
NPO
NPO+KL
RMU
WHP
LLaMA-2 HP
LLaMA-2 SW
LLaMA-2 WS
LLaMA-3 HP
LLaMA-3 SW
LLaMA-3 WS
Qwen HP
Qwen SW
Qwen WS
0.66 0.50 0.02 0.50 0.50 0.50 0.50 0.50 0.50
0.68 0.67 0.65 0.57 0.66
0.75 0.67 0.81 0.92 0.76 0.75 0.71
0.76 0.77 0.83 0.85 0.82
0.68 0.70 0.74 0.88 0.84 0.10 0.70 0.80 0.62
0.76 0.71 0.83 0.93 0.85 0.86 0.94 0.85 0.88
0.8 0.6 0.4 0.2
-0.00 -0.00 -0.00 -0.00 -0.00 -0.00 -0.00 -0.00 -0.00
+0.04 -0.04 -0.08 +0.08 -0.04
-0.00 -0.04 -0.04 +0.04 -0.12 -0.04 -0.08
+0.04 -0.00 -0.04 +0.08 -0.12
-0.00 -0.04 -0.08 +0.04 -0.00 -0.00 -0.04 -0.08 -0.00
+0.04 -0.00 -0.04 +0.08 +0.12 -0.00 +0.16 -0.04 +0.12
0.3 0.2 0.1 0.0 −0.1 −0.2 −0.3
0.77 1.00 1.00 0.00 0.00 1.00 0.83 1.00 0.91
0.74 0.93 0.74 0.99 1.00
0.82 0.92 0.80 0.93 0.93 0.97 0.95
0.89 0.98 0.89 0.99 1.00
0.82 0.96 0.84 0.91 0.99 0.04 0.98 0.99 0.93
0.90 0.98 0.90 1.00 1.00 0.98 0.99 1.00 0.97
1.0 0.8 0.6 0.4 0.2 0.0
0.60 0.00 0.00 0.00 0.00 0.00 0.00 0.00 0.20
0.80 0.80 1.00 0.00 1.00
0.60 1.00 1.00 0.00 0.00 1.00 1.00
0.60 0.60 1.00 0.00 0.80
1.00 1.00 1.00 0.00 0.00 0.00 0.80 1.00 0.80
0.00 0.00 0.00 0.00 0.00 0.00 0.00 0.00 0.00
1.0 0.8 0.6 0.4 0.2 0.0